
PREDICCIÓN DEL RENDIMIENTO ACADÉMICO MEDIANTE HÁBITOS DE ESTUDIO Y VIDEOJUEGOS

Comparación de Modelos de Regresión con Ajuste de Hiperparámetros y Ensemble

Dataset: Gaming vs Academic Performance (Kaggle - nalisha/gaming-vs-academic-performance)

Abstract

Este trabajo presenta un estudio de regresión supervisada para predecir el rendimiento académico (nota final) de 8,000 estudiantes universitarios a partir de sus hábitos de estudio, sueño, asistencia y uso de videojuegos. Se utilizó el dataset *Gaming vs Academic Performance* de Kaggle. La metodología incluyó detección de anomalías, codificación de variables categóricas, normalización Z-score y división en conjuntos de entrenamiento (70%), validación (15%) y prueba (15%). Para la predicción evaluaron cuatro modelos: Regresión Lineal, K-Nearest Neighbors (KNN), Random Forest y XGBoost. Los dos modelos de mayor potencia se sometieron a ajuste de hiperparámetros mediante Random Search con validación cruzada. Adicionalmente se construyó un ensamble evaluado por R^2 . El mejor modelo individual fue XGBoost ($R^2 = 0.925$, RMSE = 6.05, MAPE = 8.83%). Por último se hizo una evaluación con ANOVA sobre los errores absolutos, y este confirmó diferencias estadísticamente significativas entre modelos ($F = 55.16$, $p < 0.0001$). El análisis de importancia de variables reveló que las horas de estudio (55.7%) y las horas de videojuego (31.7%) son los factores dominantes en la predicción.

Introducción

El rendimiento académico de los estudiantes universitarios es un resultado que se ve influenciado por varios factores, como los hábitos de estudio, los patrones de sueño, la asistencia a clases, el nivel de estrés y otros factores como actividades de ocio como los videojuegos y uso de redes sociales. Hoy en día, rápidamente se ha visto un incremento en las horas de pantalla, sea por videojuegos en línea, como por las múltiples redes sociales diseñadas para mantener la atención del usuario, surge la pregunta de si el uso de videojuegos impacta negativamente el desempeño académico, o si existen otros factores de mayor peso.

El aprendizaje automático ofrece herramientas poderosas para modelar estas relaciones de forma no lineal y sobre grandes conjuntos de datos. Modelos como Random Forest y XGBoost han demostrado alto desempeño en tareas de regresión sobre datos tabulares, superando frecuentemente a métodos clásicos como la regresión lineal.

El presente trabajo tiene dos objetivos principales:

- Predecir la nota final de los estudiantes a partir de sus hábitos de vida y entretenimiento usando múltiples modelos de regresión.
- Cuantificar el efecto relativo de los videojuegos frente a otros hábitos sobre el rendimiento académico y comparar con sus hábitos de estudio.

Para ello se utiliza el dataset *Gaming vs Academic Performance* disponible en Kaggle, que contiene registros de 8,000 estudiantes con 13 variables de entrada. La variable objetivo es **grades**, una variable continua que representa la nota final en escala de 0 a 100 (con valores posibles hasta 118.6).

Metodología

Dataset y Variables

El dataset contiene **8,000 instancias** y **14 columnas** (incluyendo el identificador del estudiante). Las variables se dividen en:

- Numéricas (9): age, gaming_hours, study_hours, sleep_hours, attendance, social_activity, device_usage, reaction_time_ms, addiction_score, grades.
- Categóricas (3): gender (*Male/Female/Other*), gaming_genre (*FPS/RPG/Casual*), stress_level (*Low/Medium/High*).

No se encontraron valores nulos en ninguna columna. La variable objetivo *grades* presenta una distribución aproximadamente normal con media de 66.18 (DE=22.42), con acumulación en el valor máximo habitual de 100% consistente con la naturaleza de las notas escolares.




Figura 1. Distribución de la variable objetivo *grades* ($n=8,000$). Se observa acumulación en el valor máximo habitual de 100%.

Detección de Anomalías

Se aplicaron tres métodos de detección de anomalías sobre las variables numéricas principales:

- Método estadístico (desviación estándar): valores a más de 3 desviaciones estándar de la media en *gaming_hours*. No se detectaron anomalías bajo este criterio.
- Z-score: misma variable, mismo umbral. Resultado idéntico al método anterior.
- Isolation Forest (contaminación=1%): aplicado sobre *gaming_hours*, *study_hours*, *sleep_hours* y *grades*. Se detectaron y eliminaron 80 instancias (1.0% del dataset).

Preprocesamiento

El pipeline de preprocesamiento consistió en:

- Eliminación del identificador *student_id* (no aporta información predictiva).
- Codificación ordinal de *stress_level*: Low=0, Medium=1, High=2 (siguen un orden natural).

-
- One-Hot Encoding de gaming_genre (3 categorías → 3 columnas binarias) y gender (3 categorías → 3 columnas binarias), dado que ninguna tiene orden natural y gender incluye la categoría 'Other'.
 - Normalización Z-score (StandardScaler) sobre las 9 variables numéricas continuas.

El dataset final contiene **16 variables de entrada** tras el encoding y la normalización. Se consideró estrategias alternativas para gender para poder convertirlo en una columna binaria, pero más adelante en el análisis se puede observar que gender no aporta significativamente en los modelos predictivos finales. Un preprocesamiento más involucrado que One-Hot Encoding solo agregaría complejidad sin un beneficio, por lo que se decidió ir por lo más sencillo.

Partición de Datos

Se dividió el dataset en tres conjuntos:

- Entrenamiento: 70% → 5,600 instancias.
- Validación: 15% → 1,200 instancias (utilizado en el eval_set de XGBoost).
- Prueba: 15% → 1,200 instancias (evaluación final de todos los modelos).

Esta partición en tres conjuntos permite un control de sobreajuste más riguroso que un split binario estándar.

Modelos Evaluados

Se entrenaron cuatro modelos de regresión:

- Regresión Lineal Múltiple: modelo base (sklearn).
- K-Nearest Neighbors (KNN): k=5 vecinos.
- Random Forest: 200 estimadores, random_state=42.
- XGBoost: 200 estimadores, learning_rate=0.05, max_depth=5, con eval_set sobre el conjunto de validación.

Ajuste de Hiperparámetros

Para Random Forest y XGBoost se aplicó RandomizedSearchCV con 20 iteraciones y validación cruzada de 5 pliegues (métrica: R^2). Los espacios de búsqueda fueron:

- Random Forest:
 - n_estimators: {100,200,300,500}
 - max_depth: {None,5,10,15,20}
 - min_samples_split: {2,5,10}
 - min_samples_leaf: {1,2,4}
 - max_features: {'sqrt','log2',None}
- XGBoost:
 - n_estimators: {100,200,300,500}
 - learning_rate: {0.01,0.05,0.1,0.2}
 - max_depth: {3,5,7,9}
 - subsample: {0.6,0.8,1.0}
 - colsample_bytree: {0.6,0.8,1.0}.

Ensemble Ponderado

Se construyó un ensemble de los cuatro modelos asignando a cada uno un peso proporcional a su R^2 en el conjunto de prueba. Esto penaliza naturalmente a los modelos más débiles y amplifica la contribución de los mejores:

Los pesos resultantes fueron: XGB = 0.258, RF = 0.257, Lineal = 0.251, KNN = 0.234.

Métricas de Evaluación

Se calcularon cuatro métricas sobre el conjunto de prueba: R^2 (coeficiente de determinación), RMSE (raíz del error cuadrático medio), MAE (error absoluto medio) y MAPE (error porcentual absoluto medio). Adicionalmente se realizó un test ANOVA de un factor sobre los errores absolutos de los cinco modelos para determinar si las diferencias son estadísticamente significativas.

Resultados

Análisis Exploratorio

La Figura 2 presenta la matriz de correlación de las variables numéricas. La Tabla 1 muestra las correlaciones de cada variable con la nota final, ordenadas de mayor a menor.




Figura 2. Matriz de correlación de variables numéricas. Las tonalidades rojas indican correlación positiva y las azules correlación negativa.

Tabla 1. Correlación de Pearson de cada variable con grades

Variable	Correlación con grades
study_hours	0.733
reaction_time_ms	0.517
sleep_hours	0.250
attendance	0.131
age	0.008
social_activity	-0.019
device_usage	-0.468
addiction_score	-0.495
gaming_hours	-0.551

Fuente: elaboración propia a partir del dataset Gaming vs Academic Performance.

Las variables con mayor correlación positiva con la nota son **study_hours** ($r=0.733$) y **reaction_time_ms** ($r=0.517$). Por el contrario, **gaming_hours** muestra la correlación negativa más fuerte ($r=-0.551$), seguida de **addiction_score** ($r=-0.495$) y **device_usage** ($r=-0.468$). Variables como edad y actividad social muestran correlaciones prácticamente nulas.

Un análisis más detallado revela que **gaming_hours** y **study_hours** no son variables independientes: existe una correlación negativa entre ellas, lo que indica que ambas compiten por el mismo recurso, en este caso el tiempo disponible del día. Sin embargo, esta correlación no es perfecta (-1.0), lo que significa que hay estudiantes que estudian poco sin necesariamente jugar mucho, y viceversa. Esto sugiere que los videojuegos impactan la nota principalmente a través del desplazamiento de horas de estudio, más que por un efecto cognitivo o conductual propio.




Figura 3. Relación entre variables de hábitos y nota final. Se aprecia una tendencia negativa clara para gaming_hours y positiva para study_hours.

3.2 Desempeño de los Modelos

La Tabla 2 presenta los resultados comparativos de todos los modelos evaluados. Los valores corresponden al conjunto de prueba (n=1,200).

Tabla 2. Comparación de métricas por modelo en el conjunto de prueba

Modelo	R ²	RMSE	MAE	MAPE	Configuración
XGBoost (tuned)	0.9251	6.053	4.792	8.83%	300 / lr=0.05 / depth=3
Random Forest (tuned)	0.9214	6.200	4.829	9.26%	200 / depth=ilim / msl=4
Ensemble ponderado	0.9180	6.330	5.011	9.55%	Ponderado por R ²
Random Forest (base)	0.9220	6.194	4.827	—	200 estimadores
XGBoost (base)	0.9260	5.995	4.699	—	200 / lr=0.05
Regresión Lineal	0.8984	7.046	5.568	10.20%	Modelo base
KNN	0.8407	8.826	6.982	13.62%	k=5

Fuente: elaboración propia.

XGBoost con hiperparámetros ajustados obtuvo el mejor R^2 (0.925) y el menor RMSE (6.053) y MAPE (8.83%). Random Forest ajustado quedó en segundo lugar ($R^2=0.921$). Cabe notar que el ajuste de hiperparámetros no produjo mejoras sustanciales respecto a las configuraciones base, lo que sugiere que los valores por defecto de sklearn/XGBoost son buenas configuraciones iniciales para este dataset.

El ensemble ponderado ($R^2=0.918$) no supera a los modelos individuales fuertes, lo cual es esperable dado que la ponderación incluye KNN (modelo más débil, $R^2=0.841$) que arrastra el resultado. La Regresión Lineal logró un $R^2=0.898$, un resultado sorprendentemente alto para un modelo lineal, lo que indica que las relaciones en los datos son predominantemente lineales.

3.3 Importancia de Variables

La Figura 4 y la Tabla 3 muestran la importancia de las variables según el modelo Random Forest.




Figura 4. Importancia de variables según Random Forest. Las horas de estudio y de videojuego dominan la predicción.

Tabla 3. Importancia de variables (Random Forest)

Variable	Importancia	% del total
study_hours	0.5569	55.69%
gaming_hours	0.3167	31.67%
sleep_hours	0.0663	6.63%
attendance	0.0272	2.72%
reaction_time_ms	0.0068	0.68%
device_usage	0.0062	0.62%
social_activity	0.0061	0.61%
addiction_score	0.0060	0.60%
Otros (género/género/stress)	0.0078	0.78%

Fuente: elaboración propia.

Las horas de estudio concentran el **55.69%** de la importancia predictiva, y las horas de videojuego el **31.67%**. Juntas explican el 87.4% de la capacidad predictiva del modelo. Las horas de sueño aportan un 6.63% adicional. La importancia de **gaming_hours** (31.7%, segundo lugar) en el modelo Random Forest indica que esta variable no es despreciable aun conociendo **study_hours**: cubre perfiles de estudiantes que estudian poco por razones distintas a los videojuegos, a diferencia de quienes estudian poco precisamente porque juegan mucho, dos perfiles con notas distintas que solo **gaming_hours** permite distinguir. Factores demográficos (género, edad) y de género de videojuego tienen una importancia prácticamente nula (< 1% cada uno).

3.4 Gráficos de Predicción vs Valores Reales

Las Figuras 5 a 7 muestran las predicciones de los tres modelos principales contra los valores reales en el conjunto de prueba. La línea roja discontinua representa la predicción perfecta ($y=x$).




Figura 5. Predicciones vs valores reales: Regresión Lineal ($R^2=0.898$).




Figura 6. Predicciones vs valores reales: Random Forest ($R^2=0.922$)




Figura 7. Predicciones vs valores reales: Ensemble ponderado por R^2 ($R^2=0.918$).

3.5 Análisis Estadístico: ANOVA

Se aplicó un test ANOVA de un factor sobre los errores absolutos de los cinco modelos. El resultado fue $F = 55.16$, $p < 0.0001$, lo que confirma que existen diferencias estadísticamente significativas en el desempeño entre modelos. Esto valida la comparación presentada en la Tabla 2 y descarta que las diferencias observadas sean producto del azar.

4. Conclusiones

Este trabajo demostró que es posible predecir el rendimiento académico estudiantil con alta precisión a partir de hábitos de vida. Las principales conclusiones son:

- XGBoost fue el mejor modelo individual con $R^2=0.925$ y $MAPE=8.83\%$, superando a Random Forest ($R^2=0.921$), Regresión Lineal ($R^2=0.898$) y KNN ($R^2=0.841$).
- El ajuste de hiperparámetros mediante Random Search no produjo mejoras significativas sobre las configuraciones base, lo que indica que los valores por defecto de estos frameworks son robustos para datos tabulares estructurados.
- Las horas de estudio (55.7%) y las horas de videojuego (31.7%) son los factores dominantes en la predicción de la nota, explicando conjuntamente el 87.4% de la importancia del modelo.
- El impacto negativo de los videojuegos ($r=-0.551$ con la nota) es real y cuantificable, pero es superado en magnitud positiva por el efecto de las horas de estudio ($r=+0.733$).
- El ensamble ponderado no mejoró a los modelos individuales fuertes. Un ensamble que excluya o penalice más agresivamente a modelos débiles podría producir mejores resultados.
- El test ANOVA confirma con $p<0.0001$ que las diferencias de desempeño entre modelos son estadísticamente significativas.

Como trabajo futuro se recomienda explorar modelos de aprendizaje profundo (redes neuronales tabulares), aplicar selección de características más agresiva dado que el 87% de la predicción recae en solo dos variables, e incorporar técnicas de interpretabilidad como SHAP values para explicar predicciones individuales.

Referencias

- [1] Nalisha. (2023). Gaming vs Academic Performance. Kaggle. <https://www.kaggle.com/datasets/nalisha/gaming-vs-academic-performance>
- [2] Hernandez, K. (2025). *Manejo de Datos para la IA*. Universidad Galileo.